

Université de Sousse

Ecole Nationale d'Ingénieurs de Sousse



Rapport projet technique de pointe

Livrable Sujet B

Réalisé par :

Chahd Zanina

Rania Akrouf

Asma Meftah

Filière :

2^{ème} Année Informatique Appliquée

Table des matières

1. Tâche automatisée et lien avec le Sujet A.....	3
Présentation de la tâche	3
2. Architecture du Workflow n8n	3
a. Modèle et Justification	4
b. Paramètres techniques	4
3. Prompts utilisés dans les nœuds LLM : system prompt et user prompt complets.....	4
3.1. System Prompt (Instructions de l'Agent).....	4
3.2. User Prompt (Interaction).....	5
4. Détails de déploiement et Sécurité.....	5
A. Environnement : n8n cloud	5
B. Gestion des credentials et sécurisation des clés API :	5
5. Limites de l'approche n8n et Pistes d'amélioration	6
Limites actuelles :	6
Pistes d'amélioration :	6

1. Tâche automatisée et lien avec le Sujet A

Présentation de la tâche

Nous avons automatisé la tâche T2, consacrée à la validation de la cohérence des projections de la Série A. L'objectif est de développer un pipeline RAG permettant de croiser les données historiques avec les projections du business plan afin d'identifier les hypothèses optimistes, réalistes ou conservatrices. L'automatisation remplace l'analyse manuelle en extrayant instantanément les chiffres clés et en calculant les écarts de croissance pour générer un rapport.

2. Architecture du Workflow n8n

L'architecture est structurée en deux pôles stratégiques qui automatisent le cycle de vie de la donnée :




Fig1 : Workflow n8n

Branche 1 : Ingestion (déclenchée manuellement une seule fois) :

- When clicking 'Execute workflow' : Trigger manuel pour lancer l'ingestion
- Search files and folders (Google Drive) : Liste tous les fichiers du dossier FallahTech sur Drive
- Download file : Télécharge chaque fichier (PDF et XLSX) en binaire
- HTTP Request → /parse (Colab) : Envoie chaque fichier au serveur Flask/Colab pour parsing PyMuPDF/pandas et chunking
- Pinecone Vector Store1 + Default Data Loader + Recursive Character Text Splitter : Vectorise les chunks et indexe dans Pinecone

Branche 2 : Q&A; (déclenchée par le chat)

- When chat message received : Trigger chat reçoit la question de l'analyste
- AI Agent : Orchestre le retrieval et la génération avec le system prompt T2
- Mistral Cloud Chat (Mistral Large) : LLM connecté à l'AI Agent pour la génération
- Simple Memory : Mémoire de session pour maintenir le contexte multi-tour
- Pinecone Vector Store2 : Outil RAG de l'AI Agent retrieval top-10 dans l'index fallahtech1
- Embeddings HuggingFace Inference : Modèle d'embedding pour vectoriser la question
- Update a document (Google Docs) : remplit un rapport Google Docs avec la réponse de l'agent

Choix du LLM : modèle retenu, justification, paramètres (température, max_tokens)

a. Modèle et Justification

Nous avons sélectionné **Mistral Large** pour sa capacité supérieure de raisonnement sémantique et sa maîtrise des documents financiers structurés, garantissant une analyse critique fiable des écarts de croissance entre les données réelles et les projections.

b. Paramètres techniques

- **Température =0.1** : Diminue le caractère aléatoire afin de produire des réponses strictement factuelles.
- **Max Tokens =1024** : Autorise des réponses détaillées sans risque de coupure.

3. Prompts utilisés dans les nœuds LLM : system prompt et user prompt complets

3.1. System Prompt (Instructions de l'Agent)

Tu es un analyste financier senior spécialisé en due diligence pour fonds d'investissement.
Tu analyses le dossier FallahTech SARL — une startup AgriTech tunisienne en levée de fonds Série A.
Ton objectif est d'évaluer la cohérence des projections financières 2026-2029 par rapport aux données historiques 2023-2025.
Pour chaque question, tu dois répondre uniquement sous forme du tableau suivant, sans aucune modification :
| hypothèse | Valeur projetée | Valeur historique | Écart | Niveau de risque |
Contraintes obligatoires :
* Respecte strictement les 5 colonnes et leur ordre exact. Aucune colonne supplémentaire n'est autorisée.
* Chaque ligne correspond à une hypothèse financière vérifiable.
* Ne liste pas les données année par année. Regroupe-les par indicateurs (ex: Croissance annuelle moyenne, Marges, Structure de coûts).
* Utilise uniquement les informations issues des documents récupérés via le Vector Store.
* Cite la source exacte directement dans la cellule concernée (nom du fichier + numéro de page).
* Si une valeur est absente, indique "Donnée non disponible".
* N'invente, n'estime et ne complète jamais avec des hypothèses externes
Calculs :
* Lorsque possible, calcule l'écart entre valeur projetée et historique.
* Si le calcul est impossible, indique "Non calculable".
Format de sortie
* Réponds uniquement en français.
* Ne fournis aucun texte, commentaire ou explication en dehors du tableau.
* Toute réponse ne respectant pas ce format est invalide.

3.2. User Prompt (Interaction)

Analyse la cohérence des hypothèses liées aux charges d'exploitation entre 2026 et 2029 en les comparant aux données historiques 2023-2025. :Extraction multi-postes (salaires, marketing...)

Analyse la cohérence des hypothèses de chiffre d'affaires de FallahTech entre 2026 et 2029 en les comparant aux données historiques 2023-2025. : spécifique

Analyse globalement la cohérence du modèle financier de FallahTech en comparant les hypothèses de chiffre d'affaires, de coûts et de rentabilité entre 2026-2029 et 2023-2025 : global

4. Détails de déploiement et Sécurité

Le déploiement de cette solution repose sur une infrastructure agile, privilégiant le contrôle local et la sécurité des accès.

A. Environnement : n8n cloud

- n8n Cloud version 2.14.2, plan gratuit (14 jours trial, 1000 exécutions)

B. Gestion des credentials et sécurisation des clés API :

- Toutes les clés API sont stockées dans le gestionnaire de credentials n8n (chiffrement AES-256)
- Mistral Cloud API : stockée comme Bearer Auth credential dans n8n
- Pinecone API Key : stockée comme credential Pinecone dans n8n
- HuggingFace Token : stockée comme Bearer Auth credential dans n8n
- Google OAuth2 : credential Google Drive/Docs configuré via OAuth2 dans n8n
- ngrok Auth Token : configuré dans le code Colab (non exposé dans n8n)
- FallahTech est une entreprise fictive les données peuvent transiter sur les outils cloud sans restriction de confidentialité

5. Limites de l'approche n8n et Pistes d'amélioration

Limites actuelles :

- Dépendance à Google Colab : le serveur Flask/ngrok doit être relancé manuellement à chaque session Colab
- Le système présente une dépendance critique envers la connectivité Cloud et les API (Mistral AI). Toute instabilité réseau ou interruption de service externe paralyse l'intégralité de la chaîne d'analyse.
- Manque de fiabilité constante : Les réponses du modèle peuvent varier d'une exécution à l'autre, ce qui rend les conclusions instables et difficiles à standardiser.

Pistes d'amélioration :

- Multi-Agent : Créer un agent spécifique pour le calcul mathématique et un autre pour la rédaction.
- Ajouter un mécanisme de cache pour éviter de re-indexer des documents déjà traités.

